

论文 Idea: FedCHI

暂定题目

FedCHI: Cross-Heterogeneity-Aware Federated LoRA Tuning for MLLMs under Label and Modality Heterogeneity

核心研究问题

在联邦 MLLM

微调中，标签异质性和模态异质性同时存在时，模型性能下降是否超过二者单独影响之和？如果存在这种超加性退化，能否通过异质性感知的 LoRA 分解与聚合缓解？

贡献写法

1. 定义 Cross-Heterogeneity Interaction (CHI)，量化标签异质性与模态异质性的交互退化。
2. 构建一个可控实验协议，同时调节 label skew 和 modality heterogeneity。
3. 提出 FedCHI: shared LoRA + modality-specific LoRA + heterogeneity-aware aggregation + consistency loss。
4. 证明 FedCHI 在交叉异质性场景下降低额外退化，而不只是带来普通 accuracy 提升。

1. 基础公式

设四种性能：

- A_00：无标签异质性、无模态异质性。
- A_L0：只有标签异质性。
- A_0M：只有模态异质性。
- A_LM：标签异质性和模态异质性同时存在。

单独下降：

$$D_L = A_{00} - A_{L0}$$

$$D_M = A_{00} - A_{0M}$$

联合下降：

$$D_{LM} = A_{00} - A_{LM}$$

交互退化:

$$CHI = D_{LM} - D_L - D_M$$

展开后:

$$CHI = A_{L0} + A_{0M} - A_{00} - A_{LM}$$

如果 $CHI > 0$, 说明两种异质性同时存在时, 伤害超过简单相加, 存在超加性交互退化。

也可以用回归/ANOVA 写:

$$A = \beta_0 + \beta_L H_L + \beta_M H_M + \beta_{LM} H_L H_M + \epsilon$$

重点看 β_{LM} 是否显著为负。

2. 实验矩阵

最小矩阵是 2x2:

Setting	Label Heterogeneity	Modality Heterogeneity	用途
S1	无	无	upper reference
S2	有	无	单独标签异质性
S3	无	有	单独模态异质性
S4	有	有	交叉异质性

更完整的是 3x3:

Label skew / Modality hetero	M0: 无	M1: 中等	M2: 强
L0: IID	A_{00}	A_{0M1}	A_{0M2}
L1: 中等 skew	$A_{L1,0}$	$A_{L1,M1}$	$A_{L1,M2}$
L2: 强 skew	$A_{L2,0}$	$A_{L2,M1}$	$A_{L2,M2}$

标签异质性可以用 Dirichlet:

$$\alpha \in 10, 1, 0.5, 0.1$$

α 越小, label skew 越强。

模态异质性可以用 missing/modality partition:

$$p_m \in 0, 0.3, 0.6$$

或者设置客户端类型比例:

类型	模态
full	image + text
text-only	text
image-only	image

例如:

- M0: 所有客户端 image + text。
- M1: 50% full, 25% text-only, 25% image-only。
- M2: 20% full, 40% text-only, 40% image-only。

每个格子跑 3-5 个 random seeds, 报告 mean $\pm$ std, 并检验 interaction term。

3. 方法设计: FedCHI

冻结 MLLM 主体, 只训练 LoRA。

基础模型:

$$W' = W + \Delta W$$

FedCHI 不只用一个 LoRA, 而是:

$$W' = W + \Delta W_s + \sum_{m \in M_k} \Delta W_m$$

其中:

- ΔW_s : shared LoRA, 所有客户端共用。
- ΔW_m : modality-specific LoRA, 比如 text LoRA、image LoRA。
- M_k : 客户端 k 拥有的模态集合。

text-only 客户端:

$$W' = W + \Delta W_s + \Delta W_{\text{text}}$$

image-only 客户端:

$$W' = W + \Delta W_s + \Delta W_{\text{image}}$$

image-text 客户端:

$$W' = W + \Delta W_s + \Delta W_{\text{text}} + \Delta W_{\text{image}}$$

一次训练即可，不是训练两遍。前向时两个 LoRA 同时激活，反向时一起更新。

4. 本地目标函数

客户端 k 的本地训练:

$$L_k = L_{\text{task}} + \lambda L_{\text{cons}} + \mu L_{\text{prox}}$$

任务损失:

$$L_{\text{task}} = \text{CE}(f_{\theta_k}(x), y)$$

一致性损失:

$$L_{\text{cons}} = D(f(x_{\text{full}}), f(x_{\text{masked}}))$$

意思是：有完整 image + text 的样本，随机 mask 掉 image 或 text，要求输出不要差太多。

proximal loss 可选:

$$L_{\text{prox}} = \|\Delta W_s^k - \Delta W_s^g\|_2^2$$

防止本地 LoRA 偏离全局太远。

5. 聚合设计

shared LoRA 聚合所有客户端:

$$\Delta W_s^{t+1} = \sum_k \omega_k^s \Delta W_{s,k}^t$$

modality LoRA 只聚合拥有该模态的客户端：

$$\Delta W_{m,k}^{t+1} = \sum_{k:m \in M_k} \omega_k^m \Delta W_{m,k}^t$$

权重不要只按样本数，可以加入标签均衡项：

$$\omega_k^m \propto n_k \cdot r_k$$

其中 r_k 可以降低标签极度偏斜客户端的权重，或提高稀有标签/稀有模态组合的权重。

最小版可以先简单做：

$$\omega_k^m = (n_k / \text{div}_k) / \sum_j (n_j / \text{div}_j)$$

其中 div_k 表示客户端标签分布偏斜程度。越偏，权重越小。

6. Baselines

不能只比 FedAvg/FedProx，但它们必须有。

基础 FL：

- Local-only
- FedAvg
- FedProx
- SCAFFOLD
- FedAdam/FedOpt

LoRA/FedMLLM baseline：

- Local LoRA
- FedAvg-LoRA
- FedProx-LoRA
- FedMLLM baseline，如果代码能跑
- FedVLM/FedMIT 类方法，能适配就加

你的消融：

- FedCHI full
- w/o modality-specific LoRA
- w/o shared LoRA
- w/o heterogeneity-aware aggregation
- w/o consistency loss

- shared LoRA only

7. 主要指标

普通性能：

- Accuracy
- F1
- VQA accuracy
- CIDEr/BLEU, 如果做 caption
- task-specific score

交叉异质性指标：

$$\text{CHI} = A_{L0} + A_{0M} - A_{00} - A_{LM}$$

还可以报告退化率：

$$\text{Drop} = (A_{00} - A_{LM}) / A_{00}$$

FedCHI 的目标不是所有场景都 SOTA, 而是：

$$\text{CHI}_{\text{FedCHI}} < \text{CHI}_{\text{FedAvg-LoRA}}$$

也就是它能降低交互退化。

8. 最终论文主线

你这篇不是单纯算法论文，也不是单纯 benchmark。最稳的主线是：

We identify, quantify, and mitigate cross-heterogeneity interaction in federated MLLM tuning.

中文：

本文发现、量化并缓解联邦 MLLM 微调中标签异质性与模态异质性的交互退化。

这比“我们提出一个新 FedAvg

变体”强很多。你的创新点不是“又多考虑一种异质性”，而是：证明两种异质性共同存在时有额外伤害，并设计 LoRA 分解与聚合机制专门降低这个额外伤害。